

¿Qué es la Ciencia de Datos?

- La Ciencia de Datos abarca todas las herramientas y técnicas necesarias para tomar decisiones de negocio inteligentes, basadas en datos y análisis racional.
 - Va más allá de conceptos como **data mining, datawarehouse, estadística, bases de datos, big data, machine learning** y **knowledge discovery**. También involucra habilidades blandas, como comunicación eficaz, comprensión de procesos y visión estratégica.
 - Su objetivo es **alcanzar los mejores resultados posibles** y **tomar decisiones racionales**, en contraposición a la toma de decisiones solo por instinto.
-

Diferencia con el instinto en los negocios

- Históricamente, los negocios a veces se han guiado por intuición, con algunos éxitos resonantes.
 - Sin embargo, los muchos fracasos invisibles y el carácter excepcional de los grandes éxitos confirman la importancia de usar criterios racionales.
-

Niveles de la inteligencia de negocios (según Katz)

Existen tres niveles dentro de las organizaciones:

1. Nivel técnico:

- Habilidades principales: técnicas (programar, consultar bases, etc.)
- Habilidades secundarias: interpersonales

2. Mandos medios:

- Habilidades principales: interpersonales (liderazgo, persuasión)
- Habilidades secundarias: técnicas

3. Alta dirección:

- Habilidades principales: conceptuales (visión estratégica, maximización de beneficios a largo plazo)
- Habilidades secundarias: interpersonales

Cada nivel usa la información de manera diferente:

- **Técnico:** implementa ETL y análisis automatizados.
 - **Mandos medios:** traducen problemas de negocio a análisis y comunican los resultados.
 - **Alta dirección:** define la estrategia, realiza pruebas de nuevos negocios, predice el tamaño de mercado y planifica el horizonte temporal.
-

Ejemplo clave para el análisis

Para saber dónde concentrar los esfuerzos analíticos, es clave entender **cómo genera valor la organización** (comercio, industria, servicios, finanzas).

Se recomienda:

- Describir el proceso de generación de valor de la empresa.
- Asignar valores económicos y márgenes de variación a cada costo relevante.
- Identificar el factor más influyente sobre el resultado final.
- Usar esa información para decidir dónde enfocar el análisis y la estrategia.

Introducción a Datawarehousing

- **Origen de los datos:**
Las empresas han ido acumulando información valiosa (hábitos de compra, fraude, incobrabilidad, etc.) en sistemas transaccionales a lo largo del tiempo.
- **Limitaciones de los sistemas transaccionales (OLTP):**
 - Fueron diseñados para asegurar **consistencia** y ahorrar espacio, no para análisis masivo.
 - Los datos pueden estar incompletos, mal ingresados o en campos incorrectos debido a la prioridad del negocio diario sobre la calidad de los

datos.

- Suele perderse información histórica relevante porque solo se almacena la última versión de cada dato.

- **Desafíos para el análisis:**

- Datos faltantes o mal estructurados.
- Necesidad de extraer y preparar los datos antes de analizarlos.
- Es fundamental **preparar y migrar los datos** a una plataforma independiente pensada para el análisis.

- **Características del Datawarehouse (DW):**

- **Desnormalización:** Los datos se reestructuran y simplifican para facilitar los análisis (contrario a los sistemas OLTP, donde los datos son muy normalizados).
- **Optimización para la lectura:** Pensados para consultas analíticas y agregados rápidos, incluso con cálculos precalculados.
- **Conservación histórica:** Se registra la evolución de los datos, no solo el último valor.

- **Comparación OLTP vs DW:**

Característica	OLTP (Transaccional)	DW (Datawarehouse)
Estructura	3ra forma normal	2da forma normal/desnormalizado
Modelo	Eficiente y complicado	Simple y redundante
Cambios	Se pierden	Se agregan/históricos
Optimización	Para la operación diaria	Para la lectura y análisis

- **Modelos de diseño en DW:**

- **Estrella:** Una tabla de hechos central (por ejemplo, ventas) rodeada de tablas de dimensiones (atributos relacionados).

- **Constelación:** Varias tablas de hechos que pueden compartir dimensiones ("agujero de gusano").
- **Galaxia:** Combinación de varias constelaciones, incluso de distintas compañías.
- **Conclusión:**
Un datawarehouse permite analizar grandes volúmenes de datos históricos de forma eficiente, superando las limitaciones de los sistemas transaccionales tradicionales.

¿Qué es el Data Mining?

- El **Data Mining** es el proceso de explorar grandes volúmenes de datos (de forma automática o semi-automática) para **descubrir patrones y reglas** útiles que ayuden a mejorar las operaciones del negocio.
 - Permite responder preguntas como:
 - ¿Qué clientes es más probable que compren?
 - ¿Quiénes podrían dejar de pagar?
 - ¿Cuál será la demanda futura?
 - Se apoya en **datos históricos** para hacer predicciones sobre el futuro.
-

¿Por qué es importante?

- Las empresas generan y almacenan muchísimos datos (compras, redes sociales, bancos, sensores, etc.).
 - Mucha información valiosa **queda oculta** por el simple volumen de datos o no es evidente a simple vista.
 - La **cantidad de datos crece** más rápido que la capacidad de analizarlos, así que es clave aprovecharlos para anticiparse, competir mejor y tomar decisiones inteligentes.
-

Ciclo de vida del Data Mining

1. **Datos:** Suelen venir como subproducto de la operación diaria, con criterios inconsistentes y a veces poco controlados.
 2. **Preparación:**
 - Se extraen, limpian y transforman (proceso ETL: Extracción, Transformación y Carga) para dejarlos listos para análisis en un data warehouse.
 3. **Análisis:** Aplicación de técnicas de minería para encontrar patrones.
 4. **Comunicación:** Los resultados deben interpretarse, explicarse y comunicar a los responsables del negocio en términos comprensibles y útiles.
-

Puntos clave sobre el Data Mining

- **NO** es un producto de software ni una solución mágica.
 - **NO** es un fin en sí mismo, sino un proceso científico y sistemático.
 - Requiere sustento matemático y estadístico.
 - Para desplegar todo su potencial, suele necesitar integrarse con los procesos operativos de la empresa.
-

Tipos de técnicas de Data Mining

1. **Descriptivas:** Buscan patrones para explicar los datos.
 - Agrupamiento (clustering)
 - Reglas de asociación
 - Correlaciones
2. **Predictivas:** Predicen el valor de una variable a partir de otras.
 - Regresión
 - Árboles de decisión

- Redes neuronales

El objetivo es obtener **conocimiento** que sea:

- Válido (realista)
 - Novedoso
 - Potencialmente útil
 - Comprensible para los expertos del negocio
-

Relación con otras disciplinas

- El Data Mining toma conceptos de:
 - Bases de datos
 - Limpieza de información
 - Toma de decisiones
 - Aprendizaje automático
 - Estadística y probabilidad
 - Visualización de datos
 - Procesamiento en paralelo
-

Fases típicas de un proyecto de Data Mining

1. **Relevar información y necesidades**
2. **Extracción, limpieza y transformación de datos**
3. **Análisis (minería) de datos**
4. **Evaluación e interpretación de resultados**

5. Comunicación a las áreas de negocio

Introducción al Knowledge Discovery

- **¿Qué es el conocimiento?**
Es la capacidad de describir fenómenos complejos con reglas simples.
- En ciencia de datos, esto implica buscar reglas sencillas que expliquen datos complejos, usando primero estadística descriptiva y después minería de datos.
- **Problema común:** El sobreajuste (overfitting): obtener reglas que solo funcionan para la muestra analizada, pero no para nuevos casos.
 - **Soluciones:** Validar con otras muestras y exigir que las reglas tengan sentido dentro del contexto de negocio.
- Los descubrimientos que contradicen el sentido común, pero se pueden justificar y explicar, suelen aportar más valor.

Ejemplo:

Quitar prospectos “malos” bajó la cantidad de ventas concretadas, pero al analizar el esfuerzo requerido, se descubrió que era más eficiente venderles a ellos. Este insight permitió recuperar clientes y aumentar la ganancia promedio.

Herramientas OLAP y Tableros de Comando

Herramientas OLAP

- Permiten analizar datos desde múltiples dimensiones (por ejemplo: país, industria, antigüedad, nivel de crédito, etc.).
- El usuario puede “perforar” (drill down) y “rebanar” (slicing) los datos para verlos bajo distintos ángulos o combinaciones.
- Permiten mostrar rápidamente gráficos o agregados según cualquier combinación de atributos, gracias a que muchos totales ya están precalculados.
- **Jerarquías:** Los atributos pueden formar jerarquías (por ejemplo: País → Estado → Ciudad).

- **Dimensiones:** Cada jerarquía y cada atributo no jerarquizado es una dimensión analítica.
 - **Problemas comunes en OLAP:**
 - Si hay muchas dimensiones, el almacenamiento puede volverse muy grande.
 - MOLAP (multi-dimensional OLAP) necesita actualizar todo el cubo cada vez que hay nuevos datos.
-

En resumen:

- El objetivo del Knowledge Discovery es encontrar reglas simples, útiles y comprensibles que expliquen grandes volúmenes de datos.
- Las herramientas OLAP permiten a los analistas explorar la información desde distintos ángulos de forma rápida y flexible, facilitando la toma de decisiones informada y la identificación de patrones relevantes.

Tipos de OLAP

- **ROLAP (Relational OLAP):**
 - Trabaja directamente sobre bases de datos relacionales usando SQL.
 - Ventaja: aprovecha la flexibilidad de las bases relacionales.
 - Desventaja: la velocidad puede ser menor frente a grandes volúmenes.
- **HOLAP (Hybrid OLAP):**
 - Combina ventajas de MOLAP y ROLAP.
 - Preprocesa parte de los datos (como MOLAP) y genera consultas dinámicas para otras (como ROLAP).
 - Es más escalable y eficiente para casos con muchas dimensiones poco pobladas.
- **Otros conceptos:**
 - **WOLAP:** OLAP web.

- **DOLAP:** OLAP de escritorio (local).
 - No existe un estándar universal de consulta OLAP como el ODBC en SQL, aunque existe MDX (Microsoft).
-

Tableros de Comando

- Los tableros permiten monitorear múltiples áreas clave de la empresa desde una sola herramienta.
 - **Problema típico:** Si se promedian los indicadores de áreas distintas, se pueden tapar problemas críticos (por ejemplo, un mal resultado comercial oculto por buen resultado financiero).
 - Mejor: usar multiplicación de indicadores (si uno va mal, arrastra a todo el tablero).
 - El esquema de indicadores debe ser acordado y revisado con todos los responsables.
 - Los tableros pueden organizarse por áreas, por procesos o por proyectos, según la organización.
 - Hay que evitar registrar como positivo algo que es perjudicial a largo plazo (por ejemplo, agotar talento, quemar buen clima laboral, perder crédito en el mercado, etc.).
 - Un buen tablero debe ser **simple**, permitir “drill down” (investigar la causa raíz de un problema) y estar basado en datos íntegros y controlados.
-

Herramientas de Business Intelligence (BI)

Por licencia:

- **Propietarias:** SAS, SPSS, Spotfire, Qlikview.
- **Gratuitas:** Weka, R, PSPP, Rapidminer, Orange.

Por enfoque:

- Visualización (Qlikview destaca por esto)
 - Análisis estadístico y de datos (R, Weka, etc.)
-

Competencias del Científico de Datos

- Un científico de datos es como un “equipo de una sola persona”: debe dominar al menos cinco áreas diferentes (programación, estadística, bases de datos, visualización, negocio, etc.).
- Por eso, rara vez existe un verdadero “junior” en el campo: la mayoría vienen de otras profesiones donde ya tenían experiencia.
- Es un perfil multidisciplinario, que puede venir de muchas ramas.