

Resumen Completo de Probabilidad y Estadística

1. Conceptos Fundamentales

Concepto	Definición	Ejemplo
Observación	Dato individual registrado	Peso de una persona
Universo	Conjunto total de casos posibles	Todos los habitantes de Argentina
Muestra	Subconjunto representativo del universo	100 personas elegidas al azar
Variable Aleatoria	Característica que toma valores según el azar	Resultado al tirar un dado

Ejemplo: Queremos saber el promedio de calzado en una empresa con 400 empleados (universo). Tomamos una muestra aleatoria de 20 empleados y anotamos sus talles (muestra).

2. Estadística Descriptiva

Medidas de posición y dispersión:

Media (Promedio)

- **¿Qué es?**
Es el valor promedio de todos los datos. Nos da una idea general de “dónde están” los datos.
- **¿Cómo se calcula?**
Sumá todos los valores y dividí por la cantidad total de datos.
- **Fórmula:**

$$\text{Media} = \frac{\text{Suma de los valores}}{\text{Cantidad de datos}}$$

- **Ventaja:** Usa toda la información disponible.
- **Desventaja:** Muy sensible a valores extremos (outliers).

Ejemplo:

Para los datos 3, 5, 7, 7, 9:

$$\text{Media} = \frac{3 + 5 + 7 + 7 + 9}{5} = \frac{31}{5} = 6,2$$

Mediana

- **¿Qué es?**
Es el valor del medio en los datos ordenados. Divide al grupo en dos partes iguales.
- **¿Cómo se calcula?**
Ordena los datos y busca el valor central.
 - Si la cantidad es impar, es el dato que está en el centro.
 - Si es par, es el promedio de los dos valores centrales.
- **Ventaja:** No se ve afectada por valores extremos.
- **Desventaja:** Ignora los valores más alejados (solo mira el centro).

Ejemplo:

Datos ordenados: 3, 5, 7, 7, 9

Hay 5 datos (impar), la mediana es el tercero: 7.

Moda

- **¿Qué es?**
Es el valor que más veces aparece en el conjunto.
- **¿Cómo se calcula?**
Contá cuántas veces aparece cada valor y elegí el más frecuente.
- **Desventaja:** Puede no existir (si todos aparecen igual) o puede haber más de una (bimodal, multimodal).

Ejemplo:

En 3, 5, 7, 7, 9 el valor 7 aparece dos veces (los demás, solo una), así que la **moda es 7**.

Varianza

- **¿Qué es?**
Mide cuán dispersos están los datos respecto de la media (promedio).
Es el promedio de las diferencias al cuadrado de cada valor respecto a la media.
- **¿Cómo se calcula?**
 1. Calculá la media (promedio).
 2. Restá la media a cada valor y elevá esa diferencia al cuadrado.
 3. Sumá todos esos cuadrados.
 4. Dividí por la cantidad de datos menos uno (si es MUESTRA).
Dividí por la cantidad de datos (si es UNIVERSO).
- **Fórmula (para muestra):**

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

- **Ventaja:** Usa todos los datos.

Ejemplo paso a paso:

Ya tenemos la **media = 6,2**.

Calculamos cada diferencia al cuadrado:

- $(3 - 6,2)^2 = (-3,2)^2 = 10,24$
- $(5 - 6,2)^2 = (-1,2)^2 = 1,44$
- $(7 - 6,2)^2 = (0,8)^2 = 0,64$
- $(7 - 6,2)^2 = (0,8)^2 = 0,64$
- $(9 - 6,2)^2 = (2,8)^2 = 7,84$

Sumamos: $10,24 + 1,44 + 0,64 + 0,64 + 7,84 = 20,8$

Dividimos por $(n-1) = 5-1 = 4$:

$$\text{Varianza} = \frac{20,8}{4} = 5,2$$

Desvío estándar

- **¿Qué es?**
Es la raíz cuadrada de la varianza. Nos dice “en promedio, cuánto se alejan los datos de la media”, usando las mismas unidades que los datos originales.
- **¿Cómo se calcula?**
Solo sacá la raíz cuadrada de la varianza.
- **Fórmula:**

$$s = \sqrt{\text{Varianza}}$$

Ejemplo:

$$\text{Desvío estándar} = \sqrt{5,2} \approx 2,28$$

Ejemplo resuelto: Conjunto de datos: 3, 5, 7, 7, 9

- **Media:** $(3+5+7+7+9)/5 = 6,2$ (Sumá todos los valores y dividí por la cantidad de datos.)

- **Mediana:** 7 (Como hay 5 datos (número impar), la **mediana** es el valor del medio)

- **Moda:** 7 (se repite dos veces)

- **Varianza:**

1- calculás la **media** (ya la hicimos: 6,2).

2- Ahora restás la media a cada dato, elevás al cuadrado y sumás todo:

$$(3 - 6,2)^2 = (-3,2)^2 = 10,24$$

$$(5 - 6,2)^2 = (-1,2)^2 = 1,44$$

$$(7 - 6,2)^2 = (0,8)^2 = 0,64$$

$$(7 - 6,2)^2 = (0,8)^2 = 0,64$$

$$(9 - 6,2)^2 = (2,8)^2 = 7,84$$

3- Sumás estos valores:

$$10,24 + 1,44 + 0,64 + 0,64 + 7,84 = 20,8$$

4- La **varianza muestral** se divide por $(n-1)$, o sea, $5-1=4$:

$$\text{Varianza} = 20,8/4$$

$$\text{Varianza} = 5,2$$

- **Desvío estándar:** $\sqrt{5,2} \approx 2,28$ (raíz cuadrada de la variancia muestral)

4. Medidas de posición y distribución

Medidas de posición relativas: cuartiles, deciles y percentiles

Dividen los datos ordenados en partes iguales para entender la distribución interna.

Cuartiles

- **Q1 (Primer cuartil):** 25% de los datos por debajo.
- **Q2 (Segundo cuartil):** 50% de los datos por debajo (**mediana**).
- **Q3 (Tercer cuartil):** 75% de los datos por debajo.

Ejemplo con notas: 4, 5, 7, 8, 10

- Q1: Entre 4 y 5 $\rightarrow (4+5)/2 = 4,5$
- Q2: 7 (el del medio)
- Q3: Entre 8 y 10 $\rightarrow (8+10)/2 = 9$

Deciles

- Dividen los datos en 10 partes iguales.
- D1: 10% de los datos por debajo,
- D9: 90% de los datos por debajo.

1. Encontrar el rango de los datos

- Mínimo: **-2.27785**
- Máximo: **2.25915**

Rango:

$$2.25915 - (-2.27785) = 4.537$$

2. Dividir el rango en 10 intervalos (bins)

Ancho de cada intervalo:

$$4.537 / 10 = 0.4537$$

Percentiles

- Dividen los datos en 100 partes iguales.
- P1: 1% de los datos por debajo,
- P99: 99% de los datos por debajo.

Cómo calcularlos:

- Ordená los datos.
- Buscá la posición usando la fórmula:

$$\text{Posición} = \frac{k}{100} \times (n + 1)$$

(donde **k** es el percentil deseado, **n** la cantidad de datos).

4. ¿Para qué sirven estas medidas?

- **Comparar:** Tu nota/altura/etc. en percentiles muestra tu posición respecto al grupo.
- **Analizar dispersión:** Si los cuartiles están cerca, los datos son homogéneos.
- **Detectar outliers:** Valores fuera del rango típico
- **Interpretar pruebas/mediciones:** Ejemplo: percentil 90 en altura = sos más alto/a que el 90% de la población.

3. Estadística Inferencial

Estadística Inferencial paso a paso

1. Definir el objetivo y la población

Antes de hacer nada, preguntate:

- ¿Sobre qué grupo quiero aprender? (la **población**)
- ¿Qué característica quiero medir? (ej: altura, proporción de personas con una cualidad, etc.)

Ejemplo:

Quiero estimar la media de altura de los estudiantes de una facultad.

2. Tomar una muestra representativa

No podés medir a toda la población (por tiempo/costo), así que agarra una **muestra aleatoria** de tamaño n .

- **Importante:** Que la muestra sea **aleatoria** para evitar sesgos.

Ejemplo:

Elijo 50 estudiantes al azar y mido sus alturas.

3. Calcular el estimador en la muestra

Según el objetivo, calculás el valor correspondiente:

- Si querés la **media poblacional** → calculás la **media muestral (promedio)**:

$$\text{Media} = \frac{\text{Suma de los valores}}{\text{Cantidad de datos}}$$

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

- Si te interesa la **proporción** → proporción muestral:

$$\hat{p} = \frac{\text{nº de casos que cumplen la condición}}{n}$$

Proporción muestral = parte de la muestra que cumple cierta característica, respecto del total.

EJ: De 100 encuestadas, 40 contestan “sí”, así que la proporción muestral es 40/100 = 0,40 (40%).

Ejemplo:

Las alturas medidas dan una media muestral de **170 cm**.

El desvío estándar (pag 8) muestral es **8 cm**.

4. Estimar el error y la precisión

Cuando vos sacás un **promedio** o una **proporción** de una muestra, **NO sabés el valor real de toda la población**, solo lo estás “estimando”. Ese número puede estar cerca o lejos del valor verdadero.

Por eso se calcula un **margen de error**, que te dice cuánto puede variar tu estimación.

Error estándar de la media:

El **error estándar de la media** es una medida de cuánto varían los promedios si tomaras muchas muestras del mismo tamaño de la población.

- Si tus datos son parecidos entre sí (desvío estándar chico), el error será chico.
- Si tus datos son muy variados (desvío estándar grande), el error será grande.
- Si tu muestra es grande (muchos datos), el error será más chico.

$$\text{Error estándar} = \frac{s}{\sqrt{n}}$$

s: es el **desvío estándar** (pag 8) de tu muestra.

n: es la **cantidad de datos** en tu muestra.

Ejemplo:

$$\text{Error estándar} = \frac{8}{\sqrt{50}} \approx 1,13$$

5. Construir un intervalo de confianza

Un **intervalo de confianza**: Es un **rango de valores** dentro del cual **esperamos que esté el valor real de la población** (por ejemplo, la verdadera media), usando la información de una muestra, con cierta seguridad (como el 95%).

¿Cómo lo armo?

Usá esta fórmula:

$$IC = \bar{x} \pm z_{\alpha/2} \times \frac{s}{\sqrt{n}}$$

¿Qué significa cada símbolo?

- $\bar{x}$: **Media muestral** (el promedio que calculaste en tu muestra).
- s : **Desvío estándar muestral** (cuánto se alejan, en promedio, los datos de la media).
- n : **Tamaño de la muestra** (cuántos datos tenés).
- $z_{\alpha/2}$: **Valor de la tabla normal** según el nivel de confianza que quieras:
 - Para **95% de confianza**, $z_{0,025} = 1,96$
 - Para **99% de confianza**, $z_{0,005} = 2,58$



Ejemplo paso a paso

Supongamos:

- Tomaste una muestra de **50 personas** ($n=50$).

- Calculaste que la **media muestral (promedio)** es **170** ($\bar{x}=170$).
- El **desvío estándar (pag 8) muestral** es **8** ($s=8$).
- Querés un **95% de confianza**, así que usás **$z = 1,96$** .

1. Calculá el error estándar:

$$\text{Error estándar} = \frac{s}{\sqrt{n}} = \frac{8}{\sqrt{50}} \approx \frac{8}{7,07} \approx 1,13$$

2. Armá el intervalo con la fórmula:

$$IC = 170 \pm 1,96 \times 1,13$$

$$IC = 170 \pm 2,22$$

Esto te da dos valores:

- Límite inferior: $170 - 2,22 = 167,78$
- Límite superior: $170 + 2,22 = 172,22$

$$IC = (167,78 ; 172,22)$$

¿Cómo lo interpreto?

No decís “la media es 170”.

Decís:

“Con un 95% de confianza, la verdadera media poblacional está entre 167,78 y 172,22.”

Esto quiere decir que, si repitieras el muestreo muchas veces, el **95% de los intervalos** **construidos de esta manera contendrían el valor real de la media.**

¿Por qué es importante?

- No te quedás solo con el promedio; mostrás qué tan preciso es.
 - Ayuda a tomar decisiones: ¿La media es realmente distinta de un valor de referencia? ¿Hay suficiente evidencia?
 - Sirve para comparar poblaciones, productos, resultados de campañas, etc.
-

¿Qué sigue después del intervalo de confianza?

Realizar un test de hipótesis

Si querés comparar un grupo contra un valor de referencia, o comparar dos grupos (por ejemplo, si dos medios de venta generan tickets distintos), usás un **test de hipótesis**.

¿Por qué?

- El intervalo de confianza te dice “el valor está más o menos por acá”.
- El **test de hipótesis** responde:

¿La diferencia que veo es real o puede ser por azar?

¿Puedo afirmar que hay una diferencia estadísticamente significativa?

Pasos del test de hipótesis (después del intervalo de confianza)

1. Plantear las hipótesis:

- **Hipótesis nula (H_0):** no hay diferencia, o el efecto es cero (ej: la media es igual al valor de referencia).
- **Hipótesis alternativa (H_1):** hay diferencia, o el efecto es distinto de cero.

2. Elegir el test apropiado:

- Según el tipo de dato (media, proporción, varianza).
- Según si conocés o no el desvío estándar, si las muestras son dependientes o independientes, etc.

3. Calcular el estadístico de prueba:

- Usás la fórmula correspondiente (z, t, etc.) con los valores de tu muestra.

4. Determinar la zona de aceptación/rechazo:

- Según el nivel de confianza y la tabla estadística.
- Ej: para 95%, los valores críticos de z son ± 1.96 (o el valor de t si tenés muestras pequeñas).

5. Comparar tu valor calculado con la zona crítica:

- Si cae **dentro** de la zona de aceptación → no hay diferencia significativa.
- Si cae **fuera** de la zona de aceptación → hay diferencia significativa, **rechazás H_0** .

6. Concluir en términos prácticos:

- “Con los datos de la muestra, hay suficiente evidencia para afirmar que X es distinto de Y.”
- O: “No hay suficiente evidencia para afirmar que hay una diferencia.”

RESUMEN PASO A PASO COMPLETO

1. Definir objetivo y población
2. Tomar muestra aleatoria
3. Calcular el estimador (media, proporción)

4. **Estimar el error y calcular el error estándar**

5. **Construir intervalo de confianza**

6. **Realizar test de hipótesis:**

- Plantear hipótesis
- Elegir test
- Calcular estadístico de prueba
- Comparar con valores críticos
- Concluir

TEST DE HIPOTESIS

Mecanismo de test de hipótesis

Identificar hip nula (rel con lo q sabemos y la probabilidad) y alterativa (o que yo quiero probar que pasa)

Identificar nivel de confianza (hasta cuando yo me lo voy a creer)

Ver que test estamos haciendo (medias, desvíos, proporciones)

Calcular variable normalizada

Ver si es test a 1 cola o 2 colas, si puede ocurrir en una de las 2 zonas de rechazo

Calcular zona de aceptación

TEST DE MEDIAS EJEMPLO:

Ejemplo pizzería, fondo rojo y amarillo, experimento para mas clientes, segundo par: fondo rojo, segundo impar: fondo amarillo

Hipótesis nula: el promedio es el mismo

Hipótesis alternativa: el promedio es distinto

Es un test a 2 colas, comparando las medias

Caso	Variable normalizada
Comparar medias con el mismo desvío estándar previamente conocido	$z = \frac{\bar{x} - \bar{y}}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$
Comparar medias con el mismo desvío estándar pero desconocido	$T_{n_1+n_2-2} = \frac{\bar{x} - \bar{y}}{S \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$
Comparar medias con distinto desvío estándar previamente conocido	$z = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$
Comparar medias con distinto desvío estándar pero desconocidos	$I T_{n_1+n_2-2} = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$
Comparar proporciones	$z = \frac{\frac{x_1}{n_1} - \frac{x_2}{n_2}}{\sqrt{p(1-p) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}}$
Comparar varianzas	$F = \frac{S_1^2}{S_2^2}$

Es la 4, por que hay distinto desvío standard y es a futuro (desconocido)

Ejemplo de test de hipótesis

Calculo de la variable normalizada:

X medio: 351.500/350

Y medio: 340.000/365

S1: 332

S2: 352

N1: 350

N2: 365

$$T_{n_1+n_2-2} = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

Da aproximadamente 2.84

I



Ahora hay que calcular la zona de aceptación

Es (-1.96, 1.96), A MI ME DIO 2.84 cae fuera de la zona de aceptación, así que es rechazo de hipótesis nula, no generan el mismo ticket promedio el fondo rojo y amarillo.

