

INFORME COMPLETO SOBRE INTELIGENCIA ARTIFICIAL Y MACHINE LEARNING

✨ INTRODUCCIÓN

Vivimos en un mundo rodeado de Inteligencia Artificial (IA), que abarca desde capacidades mecánicas y sensoriales hasta la habilidad para aprender, razonar y crear. La IA puede clasificarse en:

- **IA Fuerte (AGI):** Inteligencia General Artificial, capaz de realizar múltiples tareas con alto nivel de complejidad.
- **IA Débil (ANI):** Inteligencia Artificial estrecha, diseñada para tareas específicas.

Ejemplo destacado: GATO

GATO es un modelo generalista de DeepMind capaz de jugar videojuegos, subtitular imágenes, chatear y manipular objetos con un brazo robótico. Puede realizar hasta 604 tareas diferentes.



DEFINICIÓN Y FUNCIONALIDAD DE LA IA

La IA imita el comportamiento inteligente sin ser necesariamente cognitiva. Sus áreas de aplicación incluyen:

- Percepción del entorno (visión computacional)
- Interacción natural con humanos (procesamiento de lenguaje natural)
- Movimiento y acción (robótica, física, diseño industrial)
- Aprendizaje (machine learning)

◆ LÍNEA DE TIEMPO HISTÓRICA

- **1950:** Alan Turing y el Test de Turing
- **1956:** John McCarthy acuña el término "IA"
- **1958:** Frank Rosenblat diseña el primer perceptrón
- **1969:** "Perceptrons" de Minsky y Papert
- **1970:** Primer invierno de la IA
- **1980:** Auge del aprendizaje automático y sistemas expertos
- **1998:** LeCun presenta las primeras CNN
- **2012 en adelante:** Explosión del Deep Learning



¿Qué es el Machine Learning (ML)?

El **Machine Learning** es una forma de programar computadoras **sin decirles exactamente qué hacer**. En lugar de escribir reglas explícitas como en la programación tradicional, dejamos que la computadora **aprenda esas reglas a partir de datos**.



Comparación: Programación Clásica vs Machine Learning



Programación Clásica

El humano escribe **todas las reglas** a mano.

El código **sigue instrucciones fijas**.

Ejemplo: reglas de tráfico, cálculos matemáticos.



Machine Learning

El humano le da **datos y resultados esperados**.

El modelo **aprende patrones** por sí mismo.

Ejemplo: reconocer una cara en una foto.

Ejemplo simple

Programación clásica:

Si querés identificar si un correo es spam, escribirías reglas como:
“Si contiene la palabra *gratis* y *urgente*, entonces marcar como spam.”

Machine Learning:

Le das al modelo miles de correos etiquetados como *spam* o *no spam*, y él **aprende solo** cuáles palabras o patrones suelen indicar spam.

¿Qué necesita el ML para aprender?

1. **Datos significativos:** muchos ejemplos, como fotos, textos, ventas, etc.
 2. **Datos representativos:** que reflejen bien la realidad y la variedad del problema.
 3. **Etiquetas (aprendizaje supervisado):** resultado esperado de cada ejemplo (por ejemplo, “spam” o “no spam”).
-

¿Qué es “generalizar”?

Es la capacidad del modelo para:

- No memorizar los datos exactos.
- Aprender **reglas generales**.
- Aplicarlas bien en **datos nuevos** que nunca había visto antes.

¿Qué es el Deep Learning?

El **Deep Learning (Aprendizaje Profundo)** es una rama del Machine Learning que utiliza **redes neuronales artificiales** muy grandes y complejas, inspiradas en el cerebro humano.

Lo que lo hace especial es que:

- ♦ **Aprende directamente de los datos crudos**, sin que un humano tenga que decirle qué características mirar.
 - ♦ Por ejemplo, en lugar de decirle: “Fíjate en el color de los ojos”, el modelo **aprende solo** que eso es relevante si lo necesita.
-

¿Cómo lo hace?

Utiliza **capas de neuronas artificiales** conectadas entre sí. Cada capa **extrae características** cada vez más complejas de los datos.

- Las primeras capas detectan cosas simples (bordes, colores).
 - Las intermedias reconocen formas (ojos, orejas).
 - Las últimas entienden conceptos (una cara, un perro, un coche).
-

¿Qué necesita el Deep Learning para funcionar bien?

1. Muchos datos

- Miles o millones de ejemplos.
- Si hay pocos datos, el modelo no aprende o se “sobreajusta” (memoriza).

2. Alto poder de cálculo

- Se entrena en **GPUs o TPUs** (placas gráficas especializadas).
- Entrenar una red neuronal profunda puede llevar horas o días.

3. Modelos preentrenados

- Son redes ya entrenadas por expertos con millones de datos.
- Se pueden reutilizar y ajustar para tareas nuevas (**transfer learning**).
- Ejemplo: usar una red que reconoce imágenes para detectar enfermedades en radiografías.



TIPOS DE APRENDIZAJE EN MACHINE LEARNING

✓ 1. Aprendizaje Supervisado

El modelo aprende a partir de ejemplos con respuesta conocida.

- **¿Cómo funciona?**
Le das al modelo entradas (X) y salidas correctas (Y). Aprende la relación para predecir nuevas salidas.
 - **Ejemplo real:**
Tenés un dataset con datos de pacientes (edad, presión, colesterol) y si tuvieron un infarto.
→ El modelo aprende a predecir si un nuevo paciente puede tener un infarto.
 - **Tareas comunes:**
 - Clasificación (spam / no spam, sí / no)
 - Regresión (predecir precios, temperaturas, etc.)
-

? 2. Aprendizaje No Supervisado

El modelo no tiene etiquetas. Solo se le dan datos crudos y trata de encontrar patrones ocultos.

- **¿Cómo funciona?**
Agrupar, segmentar o reducir los datos sin saber cuál es la respuesta correcta.
 - **Ejemplo real:**
Tenés un dataset con hábitos de consumo de clientes, pero no sabés qué tipo de cliente es cada uno.
→ El modelo agrupa clientes similares sin que le digas cómo.
 - **Tareas comunes:**
 - Clustering (agrupamiento)
 - Reducción de dimensionalidad (PCA, Autoencoders)
-

3. Aprendizaje por Refuerzo (Reinforcement Learning)

El modelo **aprende con prueba y error**. No tiene ejemplos directos, sino que explora y recibe recompensas o castigos.

- **¿Cómo funciona?**

El agente prueba acciones en un entorno, observa el resultado y ajusta su estrategia para maximizar la recompensa total.

- **Ejemplo real:**

Un robot que aprende a caminar. Al principio se cae, pero con el tiempo va aprendiendo qué movimientos lo mantienen en pie.

- **También se usa en:**

- Juegos (como AlphaGo o juegos de Atari)
- Control de tráfico
- Finanzas automatizadas

TIPOS DE PROBLEMAS EN ML

1. Clasificación

Predecir **categorías** o **etiquetas discretas**.

- **Pregunta típica:** ¿A qué clase pertenece esta entrada?
 - **Salida esperada:** Una **clase**, como “sí” o “no”, “spam” o “no spam”, “perro”, “gato” o “pájaro”.
 - **Ejemplos reales:**
 - ¿Este email es spam?
 - ¿Este cliente va a pagar o no?
 - ¿Qué tipo de flor es esta?
-

2. Regresión

Predecir **valores numéricos continuos**.

- **Pregunta típica:** ¿Cuál será el valor exacto de salida?
 - **Salida esperada:** Un número.
 - **Ejemplos reales:**
 - ¿Cuál será el precio de esta casa?
 - ¿Cuántos productos se venderán mañana?
 - ¿Cuál será la temperatura máxima?
-

3. 🌿 Clustering (Agrupamiento)

Agrupar ejemplos **similares entre sí, sin tener etiquetas previas**.

- **Pregunta típica:** ¿Cuáles elementos son parecidos y pueden agruparse?
 - **Salida esperada:** Clusters (grupos) de datos parecidos.
 - **Ejemplos reales:**
 - Segmentar clientes por comportamiento de compra.
 - Agrupar noticias por tema sin saber los temas de antemano.
 - Detectar anomalías o fraudes (lo que no encaja en ningún grupo).
-

4. ✂️ Reducción de Dimensionalidad

Simplificar los datos **conservando la información más relevante**.

- **Pregunta típica:** ¿Cómo puedo representar estos datos con menos variables?
- **Salida esperada:** Una versión más “ligera” de los datos.
- **Ejemplos reales:**
 - Comprimir imágenes sin perder calidad.

- Visualizar datos complejos en 2D o 3D.
- Quitar ruido de señales o detectar patrones escondidos.



Comparación rápida

Tipo de problema	¿etiquetas?	¿Qué predice?	Tipo de salida
Clasificación	✓ Sí	Clase / categoría	Discreta (ej. "gato")
Regresión	✓ Sí	Valor numérico	Continua (ej. 78.5)
Clustering	✗ No	Grupos de datos similares	Agrupamiento
Reducción de dimensionalidad	✗ No	Versión comprimida del dato	Variables reducidas



MODELOS DE MACHINE LEARNING



MODELOS NO SUPERVISADOS

Se entrenan sin etiquetas. Buscan estructuras ocultas o patrones en los datos.

♦ K-Means (Clustering)

- ¿Qué hace? Agrupar los datos en "k" grupos (clusters) según su similitud.

- Cómo funciona: Elige aleatoriamente centros (centroides), agrupa los datos según cercanía, y ajusta los centroides hasta estabilizarse.
 - Ejemplo: Segmentar clientes por comportamiento.
-

♦ PCA (Análisis de Componentes Principales)

- ¿Qué hace? Reduce la cantidad de variables manteniendo la máxima información posible.
 - Para qué sirve: Visualizar datos complejos, acelerar modelos, quitar ruido.
 - Ejemplo: Comprimir una imagen sin perder calidad visual.
-

♦ DCT (Transformada Discreta del Coseno)

- Similar a PCA pero usada principalmente en procesamiento de imágenes y señales.
 - Ejemplo: JPEG usa DCT para comprimir imágenes eliminando información irrelevante para el ojo humano.
-

♦ Autoencoders

- Tipo de red neuronal que aprende a comprimir y luego reconstruir los datos.
 - ¿Para qué sirve?:
 - Reducción de dimensionalidad
 - Eliminación de ruido
 - Generación de nuevos datos (como imágenes)
 - Detección de anomalías
-

Se entrenan con entradas y salidas etiquetadas. Aprenden a predecir.

♦ Árboles de decisión

- Dividen los datos según reglas lógicas (“¿es mayor que...?”).
- Fáciles de interpretar.

🌲 Random Forest

- Ensamble de muchos árboles simples. Promedian el resultado.
- Robusto y preciso, menos propenso al sobreajuste.

⚡ XGBoost / LightGBM

- Son árboles “inteligentes” entrenados uno tras otro, corrigiendo errores del anterior.
- Muy usados en competencias de ML (como Kaggle) por su alto rendimiento.
- LightGBM es más rápido y liviano que XGBoost en datasets grandes.

♦ Redes Neuronales Profundas (Deep Neural Networks)

- Inspiradas en el cerebro. Tienen capas de neuronas artificiales.
- Sirven para:
 - Reconocimiento de voz
 - Clasificación de imágenes
 - Traducción automática
 - Diagnóstico médico
- Pueden resolver tareas muy complejas, pero requieren:
 - Muchos datos
 - Mucha potencia computacional

✓ VALIDACIÓN Y EVALUACIÓN DE MODELOS

Cuando entrenás un modelo de ML, no alcanza con que funcione bien *en los datos que ya has visto*. Lo importante es que **generalice bien a datos nuevos**.

🔄 1. Cross Validation (Validación Cruzada)

Divide los datos en varias partes (folds), entrena con algunas y valida con las otras.

- **¿Para qué sirve?** Asegura que el modelo no se ajusta solo a un subconjunto.
 - **Típico:** k-fold (por ejemplo, 5-fold → se divide en 5 partes).
 - **Ventaja:** Evaluación más robusta.
-

🔪 2. Train/Test Split

Separas los datos en dos partes:

- **Entrenamiento:** para enseñar al modelo.
 - **Test:** para medir qué tan bien aprendió.
 - **Ejemplo típico:** 80% entrenamiento / 20% test.
-

📅 3. Series Temporales (Time Series)

¡CUIDADO! Acá **no podés mezclar pasado y futuro**.

- **Error común:** usar datos del futuro para predecir el pasado.
 - **Problema:** *Information leak* (fuga de información).
 - **Solución:** entrenar solo con datos anteriores al punto que querés predecir.
-

MÉTRICAS DE CLASIFICACIÓN

Cuando la tarea es predecir categorías (spam/no spam, sí/no, etc.)

Matriz de Confusión

	Predicho Positivo	Predicho Negativo
Real Positivo	TP (Verdadero Positivo)	FN (Falso Negativo)
Real Negativo	FP (Falso Positivo)	TN (Verdadero Negativo)

1. Precisión (*accuracy*)

Qué porcentaje de las predicciones fueron correctas.

$$\text{Precisión} = \frac{TP + TN}{TP + TN + FP + FN}$$

Ejemplo:

Si de 100 casos tu modelo acertó 90 (suma de TP y TN), la precisión es 90%.

2. Sensibilidad (*recall o true positive rate*)

Qué porcentaje de los **positivos reales** los detectaste como positivos.

$$\text{Sensibilidad} = \frac{TP}{TP + FN}$$

Ejemplo:

Si hubo 20 casos realmente urgentes y tu modelo solo detectó 15, la sensibilidad es $15/20 = 75\%$.

3. Especificidad (*true negative rate*)

Qué porcentaje de los **negativos reales** los detectaste como negativos.

$$\text{Especificidad} = \frac{TN}{TN + FP}$$

4. Valor predictivo positivo (*precision* o *PPV*)

De todos los que dijiste que eran positivos, ¿cuántos realmente lo eran?

$$\text{Precisión (PPV)} = \frac{TP}{TP + FP}$$

5. Valor del modelo (Matriz de valoración)

Acá usás **pesos** de negocio para cada combinación.

La fórmula general es:

$$V = VTP \times TP + VTN \times TN + VFP \times FP + VFN \times FN$$

- VTP: Valor de un verdadero positivo (ej: \$1000 por cada venta lograda)
- VFP: Penalidad de un falso positivo (ej: -\$100 por cada llamada sin venta)
- VFN: Penalidad de un falso negativo (ej: \$0, no ganás nada)
- VTN: Valor de un verdadero negativo (ej: \$0, tampoco ganás nada)

Así, le ponés un **valor concreto** (plata, vidas, etc.) al rendimiento del modelo, no solo un porcentaje abstracto.

¿Cuándo usar cada indicador?

- **Precisión:**
Útil cuando **no hay mucha diferencia** entre equivocarse en un positivo o en un negativo.
Ejemplo: un modelo para detectar si alguien prefiere mate o café. No cambia la vida.
 - **Sensibilidad:**
Importa cuando **NO querés dejar pasar ningún positivo**.
Ejemplo: detectar enfermedades graves. Mejor un falso positivo (asustar a alguien sano) que un falso negativo (dejar sin tratar a un enfermo).
 - **Especificidad:**
Importa cuando **NO querés alarmar por error**.
Ejemplo: un test de drogas en una empresa, donde un falso positivo puede hacerle daño a alguien inocente.
 - **Valor del modelo:**
Cuando cada error o acierto **tiene un valor distinto para el negocio** (plata, vidas, etc).
Ejemplo: ventas, salud, fraudes bancarios.
-



MÉTRICAS DE REGRESIÓN

Cuando la tarea es predecir valores numéricos (precio, edad, temperatura...)

♦ MAE (Mean Absolute Error)

Promedio del **error absoluto** entre lo que predijo el modelo y el valor real. |

♦ MSE (Mean Squared Error)

Similar al MAE pero **castiga más** los errores grandes.

♦ R^2 (R-cuadrado)

Mide qué tanto del comportamiento de los datos **explica** el modelo.

- Valor cerca de 1 → el modelo explica muy bien los datos.
- Valor cerca de 0 → no explica casi nada.

TRANSFORMACIÓN DE LOS DATOS

Antes de entrenar un modelo, es necesario transformar los datos en un formato que la máquina pueda entender: vectores numéricos.

Categorías → One Hot Encoding

Convierte etiquetas categóricas (tipo texto) en columnas binarias.

- Ejemplo:
 - Dato original: **Color = Rojo, Verde, Azul**
 - Se transforma en:

	R	V	A
	1	0	0
	0	1	0

0 0 1

¿Para qué sirve? Permite que el modelo no interprete que 'Rojo' es mayor que 'Azul', ya que son etiquetas, no números con orden.

Texto → Bag of Words

Representa el texto como frecuencia de palabras.

- Ejemplo:
Frase: “Me gusta la IA”
Vocabulario: [“me”, “gusta”, “la”, “IA”]

→ Vector: [1, 1, 1, 1]
 - ¿Qué pierde? El orden de las palabras.
 - ¿Qué gana? Simpleza, ideal para modelos básicos.
-

Imágenes → Canales RGB

Una imagen se descompone en 3 matrices (rojo, verde, azul), cada una con valores de intensidad (0 a 255).

- Ejemplo:
Una imagen de 100x100 píxeles → 3 matrices de 100x100.
Cada pixel tiene 3 valores: R, G y B.
 - ¿Para qué sirve? Esto convierte una imagen en una gran matriz numérica, que puede ser procesada por redes neuronales.
-

CASOS DE USO REALES

Ahora veamos aplicaciones reales donde se usan estos modelos y transformaciones



Conversión Online

Predecir si un visitante de una web/app realizará una acción valiosa (comprar, registrarse, etc.)

- ¿Para qué sirve?
 - Decidir cuánto invertir en publicidad.
 - Mostrar contenido personalizado.
- Ejemplo: Google Ads ajusta pujas automáticamente según probabilidad de conversión.



Upselling y Cross-selling

Predecir si un cliente va a:

- Comprar una versión más cara (upselling)
- Comprar productos complementarios (cross-selling)
- ¿Para qué sirve?
 - Personalizar recomendaciones.
 - Automatizar ofertas en ecommerce.
- Ejemplo: Amazon sugiere “Productos que suelen comprarse juntos”.



Predicción de Churn

Estimar la probabilidad de que un cliente se dé de baja o deje de usar un servicio.

- ¿Para qué sirve?

- **Detectar clientes en riesgo.**
 - **Lanzar campañas de retención.**
 - **Ejemplo: Spotify detecta usuarios inactivos y ofrece promociones para que no cancelen.**
-

Sistemas de Recomendación

Sugerir contenido/productos personalizados según el comportamiento del usuario.

- **¿Para qué sirve?**
 - **Aumentar engagement y ventas.**
 - **Mejorar experiencia de usuario.**
 - **Ejemplo: Netflix recomienda series según tus gustos + lo que vieron usuarios similares.**
-

ÉTICA EN IA Y ML

Principales preocupaciones:

- **Sesgos de datos y algoritmos**
- **Discriminación (racial, de género)**
- **Ejemplos: COMPAS, Google Fotos etiquetando mal**

Soluciones:

- **Evaluación constante de sesgos**
- **Desarrollo con principios éticos: seguridad, privacidad, equidad**

Legislación Argentina:

- **Ley 25.326 (2000):** protección de datos personales

CONCEPTOS CLAVE

- **Datos:** personales, sensibles, biométricos, genéticos
- **Sesgos:** estadístico, cultural, cognitivo
- **Evaluación:** métricas acordes al negocio

CIERRE

La IA y el ML transforman industrias y mejoran nuestras vidas. Pero también requieren responsabilidad, evaluación constante y compromiso ético para evitar perpetuar injusticias.