


REDES NEURONALES RECURRENTE





Contexto

- Las Redes Neuronales o las Redes Convolucionales permiten procesar un solo dato a la vez (como un sonido o una imagen), pero si tenemos una **secuencia** de sonidos (una conversación) o de imágenes (un video), estas arquitecturas no estarán en capacidad de procesar este tipo de datos secuenciales, pues no tienen un recuerdo de las muestras vistas pasadas.
- Los datos secuenciales se caracterizan porque los elementos en una secuencia aparecen en un cierto orden y no son independientes unos de otros.
- EN LAS SECUENCIAS, EL ORDEN DE LOS ELEMENTOS SÍ IMPORTA.



Contexto


- Las secuencias vienen en distintos “sabores”, clasificadas según cómo sean la/s entrada/s y la/s salida/s
(ver <https://karpathy.github.io/2015/05/21/rnn-effectiveness/>)




Qué son las Redes Recurrentes?


- Están diseñadas para modelar secuencias: son capaces de recordar información pasada y procesar nuevos eventos en consecuencia.
- En una red prealimentada estándar, la información fluye de la entrada a la capa oculta y después de la capa oculta a la capa de salida. Por otro lado, en una red recurrente, la capa oculta obtiene su entrada tanto de la capa de entrada como de la capa oculta a partir del paso temporal anterior.

Red neuronal prealimentada estándar



Red neuronal recurrente






El flujo de información en pasos temporales adyacentes en la capa oculta permite a la red tener un recuerdo de los eventos pasados. Este flujo de información se muestra normalmente como un bucle, también conocido como **recurrent edge** o **borde recurrente** en notación de gráficos, que es de donde adquiere su nombre esta arquitectura general.


Cada borde directo (las conexiones entre cajas) en la representación de la RNN que acabamos de ver está asociado con una matriz ponderada. Estos pesos no dependen del momento t ; por tanto, se comparten a través del eje temporal. Las diferentes matrices ponderadas en una capa única de RNN son:

- : La matriz ponderada entre la entrada y la capa oculta h , W_{xh} .
- : La matriz ponderada asociada al borde recurrente, W_{hh} .
- : La matriz ponderada entre la capa oculta y la capa de salida, W_{hy} .




Para calcular las activaciones se pueden usar dos enfoques:

Fórmula 1: $h^{(t)} = \phi_h(W_{xh} x^{(t)} + W_{hh} h^{(t-1)} + b_h)$



Fórmula 2: $h^{(t)} = \phi_h(W_h [x^{(t)}; h^{(t-1)}]^T + b_h)$




Resultado final:

$$y^{(t)} = \phi_y(W_{hy} h^{(t)} + b_y)$$


Cálculo de gradientes

- En los ´90 se desarrolla el algoritmo de “Backpropagation through Time” (BPTT). Este propone que los gradientes a lo largo del tiempo se pueden calcular como un producto entre los gradientes a cada intervalo de tiempo
- Esto provoca problemas de desvanecimiento o explosión de gradientes


Desaparición
del gradiente: $|w_{hh}| < 1$




Explosión
del gradiente: $|w_{hh}| > 1$



Deseable: $|w_{hh}| = 1$



- Para entrenar a las RNN hay dos enfoques:
- TBPTT: gradientes truncados en el tiempo (truncated backpropagation through time)
- Se recortan los gradientes por encima de un umbral. Esto implica que no se conserva el 'recuerdo' de eventos más lejanos. Soluciona la explosión del gradiente pero no el desvanecimiento.
- LSTM (1997): memoria larga de corto plazo (long short-time memory)
- Se introduce una celda de memoria con puertas:
- Puerta del olvido f
- Puerta de entrada i y g
- Puerta de salida o



PREGUNTAS????
GRACIAS POR ESCUCHAR!!!

FUENTES: * "Python Machine Learning", Sebastian Raschka & Vahir Mirjalili, Marcombo, 2019, 2da Ed. en español
* "Redes Neuronales Recurrentes", Codificando Bits,
<https://codificandobits.com/blog/introduccion-redes-neuronales-recurrentes/>