

MÉTODOS DE BAYES INGENUO

*** ES UN CONJUNTO DE MÉTODOS CLASIFICADORES DE APRENDIZAJE SUPERVISADO**

*** EL REQUISITO 'INGENUO' ES QUE CADA PAR DE CARACTERÍSTICAS DE LAS MUESTRAS SEAN CONDICIONALMENTE INDEPENDIENTES ENTRE SÍ DADA UNA ETIQUETA DE CLASE (A VECES, CUMPLIRLO ES DIFÍCIL)**

*** USA LAS PREMISAS DEL TEOREMA DE BAYES PARA HACER LA CLASIFICACIÓN**

- ▶ QUÉ DICE EL TEOREMA DE BAYES?
- ▶ Dada la variable de clase 'y' y el vector de características $x_1, x_2, \dots, x_n$, la probabilidad condicional se escribe como:
- ▶ $P(y | x_1, x_2, \dots, x_n) = P(y) * P(x_1, x_2, \dots, x_n | y) / P(x_1, x_2, \dots, x_n)$
- ▶ Pero bajo la suposición 'naive' de independencia condicional de:
- ▶ $P(x_i | y, x_1, x_2, \dots, x_{(i-1)}, x_{(i+1)}, \dots, x_n) = P(x_i | y)$ para todo i
- ▶ la relación se simplifica:
- ▶
$$P(y | x_1, x_2, \dots, x_n) = P(y) * \prod_{i=1}^n P(x_i | y) / P(x_1, x_2, \dots, x_n)$$
- ▶

TEOREMA DE BAYES

- ▶ ES MUY RÁPIDO PARA ENTRENAR COMPARADO CON MODELOS MÁS SOFISTICADOS, PUES, COMO LA DISTRIBUCIÓN CONDICIONAL ESTÁ DESACOPLADA, CADA DISTRIBUCIÓN SE PUEDE ESTIMAR COMO UNIDIMENSIONAL
- ▶ REQUIERE UNA PEQUEÑA CANTIDAD DE DATOS PARA ESTIMAR LOS PARÁMETROS NECESARIOS
- ▶ FUNCIONA NOTABLEMENTE BIEN EN PROBLEMAS DE LA VIDA REAL, COMO CLASIFICACIÓN DE TEXTOS O FILTRADO DE SPAM
- ▶ AÚN SI NO SE CUMPLE LA INDEPENDENCIA ESTRICTA DE LAS CARACTERÍSTICAS, DA RESULTADOS BASTANTE BUENOS

VENTAJAS

▶ AUNQUE ES UN CLASIFICADOR DECENTE, SE SABE QUE ES UN MAL ESTIMADOR, POR LO QUE LAS PROBABILIDADES PREDICHAS NO DEBEN TOMARSE MUY EN SERIO

DESVENTAJAS

- ▶ EXISTEN DISTINTOS MÉTODOS CLASIFICADORES QUE DIFIEREN EN LAS SUPOSICIONES QUE HACEN MIRANDO LA DISTRIBUCIÓN DE $P(x_i | y)$
- ▶ @ GAUSSIAN NAIVE BAYES: SUPONE QUE LA PROBABILIDAD $P(x_i | y)$ ES GAUSSIANA
- ▶ @ MULTINOMIAL NAIVE BAYES: SUPONE LOS DATOS SIGUEN UNA DISTRIBUCIÓN MULTINOMIAL
- ▶ @ COMPLEMENT NAIVE NAYES: USA UNA ADAPTACIÓN DE LA MULTINOMIAL ADAPTADA PARA DATASETS DESBALANCEADOS
- ▶ @ BERNOULLI NAIVE BAYES: SUPONE QUE LOS DATOS SIGUEN UNA DISTRIBUCIÓN DE BERNOULLI
- ▶ @ CATEGORICAL NAIVE BAYES: PARA DATASETS CON CARACTERÍSTICAS CATEGÓRICAS

TIPOS DE CLASIFICADORES

► *GaussianNB*

► SUPONE QUE LA PROBABILIDAD ES GAUSSIANA

► $P(x_i | y) = 1 / (2 * \pi * \sigma^2)^{0.5} * \exp(-(x_i - \mu)^2 / (2 * \sigma^2))$

► σ Y μ SE ESTIMAN USANDO MÁXIMA PROBABILIDAD

► `class sklearn.naive_bayes.GaussianNB(*, priors=None, var_smoothing=1e-09)`

► MÉTODOS PPALES: `fit`, `predict`, `score`

```
>>> from sklearn.datasets import load_iris
>>> from sklearn.model_selection import train_test_split
>>> from sklearn.naive_bayes import GaussianNB
>>> X, y = load_iris(return_X_y=True)
>>> X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.5, random_state=0)
>>> gnb = GaussianNB()
>>> y_pred = gnb.fit(X_train, y_train).predict(X_test)
>>> print("Number of mislabeled points out of a total %d points : %d" ... % (X_test.shape[0], (y_test != y_pred).sum()))
Number of mislabeled points out of a total 75 points : 4
```

► MultinomialNB

- Implementación para datos distribuidos multinomialmente, es decir, características DISCRETAS
- Es una de las dos variantes clásicas de Naive Bayes utilizadas en la clasificación de texto (donde los datos se representan típicamente como conteos de vectores de palabras, aunque también se sabe que los vectores tf-idf funcionan bien en la práctica))
- La distribución está parametrizada por vectores n-dimensionales para cada clase, donde 'n' es el número de características (en la clasificación del texto, el tamaño del vocabulario) y cada elemento es la probabilidad $P(x_i | y)$ de que aparezca una característica 'xi' en una muestra perteneciente a la clase
- Los parámetros se estiman mediante una versión suavizada de máxima verosimilitud, es decir, conteo de frecuencia relativa que evita las probabilidades cero en los cálculos posteriores. El ajuste se denomina suavizado de Laplace o de Lidstone (cambia el valor de un parámetro)
- `class sklearn.naive_bayes.MultinomialNB(*, alpha=1.0, force_alpha='warn', fit_prior=True, class_prior=None)`

```
>>> import numpy as np
>>> rng = np.random.RandomState(1)
>>> X = rng.randint(5, size=(6, 100))
>>> y = np.array([1, 2, 3, 4, 5, 6])
>>> from sklearn.naive_bayes import MultinomialNB
>>> clf = MultinomialNB(force_alpha=True)
>>> clf.fit(X, y)
      MultinomialNB(force_alpha=True)
>>> (clf.predict(X[2:3]))
[3]
```


► ComplementNB

- CNB es una adaptación del algoritmo multinomial Naive Bayes (MNB) estándar que es especialmente adecuado para conjuntos de datos desequilibrados
- CNB usa estadísticas del *complemento* de cada clase para calcular los pesos del modelo
- Los inventores de CNB muestran empíricamente que las estimaciones de parámetros para CNB son más estables que las de MNB
- CNB supera regularmente a MNB (a menudo por un margen considerable) en tareas de clasificación de texto
- `class sklearn.naive_bayes.ComplementNB(*, alpha=1.0, force_alpha='warn', fit_prior=True, class_prior=None, norm=False)`
- Rennie, J. D., Shih, L., Teevan, J., & Karger, D. R. (2003). Tackling the poor assumptions of naive bayes text classifiers. In ICML (Vol. 3, pp. 616-623)

► BernoulliNB

- Implementación para datos discretos, que se distribuyen de acuerdo con distribuciones multivariadas de Bernoulli: puede haber varias características, pero se supone que cada una es una variable de valor binario (Bernoulli, booleano).
- Esta clase requiere que las muestras se representen como vectores de características con valores binarios; si se entrega cualquier otro tipo de datos, una instancia de BernoulliNB puede binarizar su entrada (dependiendo del parámetro binarizar).
- La regla de decisión para BernoulliNB difiere de la regla de MultinomialNB en que penaliza explícitamente la no ocurrencia de una característica que es un indicador de clase (la variante multinomial simplemente ignoraría una característica que no ocurre)
- En el caso de la clasificación de texto, se pueden usar vectores de aparición de palabras (en lugar de vectores de recuento de palabras) para entrenar y usar este clasificador
- BernoulliNB podría funcionar mejor en algunos conjuntos de datos, especialmente aquellos con documentos más cortos. Es recomendable evaluar ambos modelos, si el tiempo lo permite
- `class sklearn.naive_bayes.BernoulliNB(*, alpha=1.0, force_alpha='warn', binarize=0.0, fit_prior=True, class_prior=None)`

► CategoricalNB

- Implementación para datos distribuidos categóricamente
- Asume que cada característica, que está descrita por el índice 'i', tiene su propia distribución categórica
- Para cada característica 'i' del conjunto de entrenamiento X, CategoricalNB estima una distribución categórica para cada característica i de X condicionada a la clase y
- El conjunto de índices de las muestras se define como $J=\{1, \dots, m\}$, con 'm' el número de muestras.
- La probabilidad de categoría 't' en una característica 'i' dada la clase 'c' se estima como:
- $P(x_i=t \mid y=c; \alpha) = (N_{tic} + \alpha) / (N_c + \alpha * N_i)$
- donde 'N_{tic}' es el nro de veces que la categoría 't' aparece en las muestras x_i que pertenecen a la clase 'c', 'N_c' es el nro de muestras con clase 'c', 'alpha' es el parámetro de suavizado y 'n_i' es el nro de categorías disponibles de la característica 'i'
- CategoricalNB asume que la matriz de muestra X está codificada (por ejemplo, con la ayuda de OrdinalEncoder) de modo que todas las categorías para cada característica 'i' se representan con números 0, 1, ..., n_i - 1 donde 'n_i' es el número de categorías de característica 'i' disponibles
- `class sklearn.naive_bayes.CategoricalNB(*, alpha=1.0, force_alpha='warn', fit_prior=True, class_prior=None, min_categories=None)`

- ▶ Los modelos Naive Bayes se pueden utilizar para abordar problemas de clasificación a gran escala para los que el conjunto de entrenamiento completo podría no caber en la memoria
- ▶ Para manejar este caso, MultinomialNB, BernoulliNB y GaussianNB exponen un método de ajuste parcial 'partial_fit' que se puede usar de manera incremental como se hace con otros clasificadores, como se demuestra en "Out-of-core classification of text documents"
- ▶ Todos los clasificadores Naive Bayes admiten la ponderación de la muestra (simple weighting)
- ▶ Al contrario del método de ajuste 'fit', la primera llamada a 'partial_fit' debe recibir la lista de todas las etiquetas de clase esperadas

► DUDAS, CONSULTAS?

► VAMOS A VER ALGUNOS EJEMPLOS

► FUENTE:

► https://scikit-learn.org/stable/modules/naive_bayes.html#naive-bayes

GRACIAS POR SU ATENCIÓN!